StreamView Analytics — Evaluación de experiencia 2

ADY1104 · Visualización de datos · Octubre de 2026

Audiencias: dirección ejecutiva y equipo de contenidos/adquisición.

Fuente: dos CSV oficiales de películas y series, corte 2025, en data/raw/.

1. Objetivo y continuidad con la evaluación 1

La evaluación 1 estableció la limpieza, las claves y las vistas analíticas del catálogo. Esta entrega transforma esas vistas en dos tableros interactivos para decisiones diferentes. El tablero ejecutivo resume composición, cobertura geográfica e idiomas. El tablero de contenidos combina valoración, popularidad, talento y finanzas para explorar oportunidades de adquisición. Ambos trabajan sobre los mismos 31.991 contenidos únicos y conservan los CSV originales sin modificación.

Problema de negocio: las áreas necesitan una lectura común del catálogo para priorizar inversiones y adquisiciones, pero los recuentos por categorías solapadas, la calidad de fechas y la cobertura financiera parcial pueden producir conclusiones equivocadas. Objetivo de comunicación: primero mostrar tamaño y concentración de la oferta a dirección; después ofrecer al equipo de contenidos señales comparables de popularidad, valoración y costos, con sus restricciones a la vista. Los archivos no incluyen usuarios, reproducciones ni retención, por lo que esta evaluación no atribuye comportamiento de audiencia al catálogo.

2. Arquitectura y herramientas

data/raw/ → función de preparación aprobada en EP1 (src/data_cleaning.py) → vistas analíticas en memoria → aplicación Python (dashboard/app.py) y seis exportaciones CSV locales (powerbi/data/) para el informe Power BI (powerbi/StreamView_EP2.pbip). EP1 no generó un CSV persistente en data/processed/; EP2 reconstruye las mismas vistas desde los originales sin alterarlos. El treemap de géneros se dibuja con D3 dentro de la aplicación. Plotly aporta barras, dispersión y mapas; Streamlit aporta navegación, filtros y descarga; Power BI aporta modelo tabular, medidas DAX y una versión de los paneles para escritorio.

Se eligió Python por la limpieza trazable y el análisis de datos; D3 por el treemap con interacción específica; Power BI por el modelo de datos y la experiencia de exploración de negocio. Esta combinación cumple el requisito de integración sin atribuir a una herramienta cálculos que realiza otra.

Las dos fuentes son netflix_movies_detailed_up_to_2025.csv (16.000 filas) y netflix_tv_shows_detailed_up_to_2025.csv (16.000 filas). Comparten identificador, tipo, título, fecha, año, género, país, idioma, popularidad, votos y nota. Solo películas aporta presupuesto e ingresos. La integración se realiza por una clave compuesta de tipo e identificador, y las categorías multivalor pasan a tablas relacionadas. Las seis exportaciones de Power BI son derivados de estas mismas vistas; no constituyen fuentes independientes.

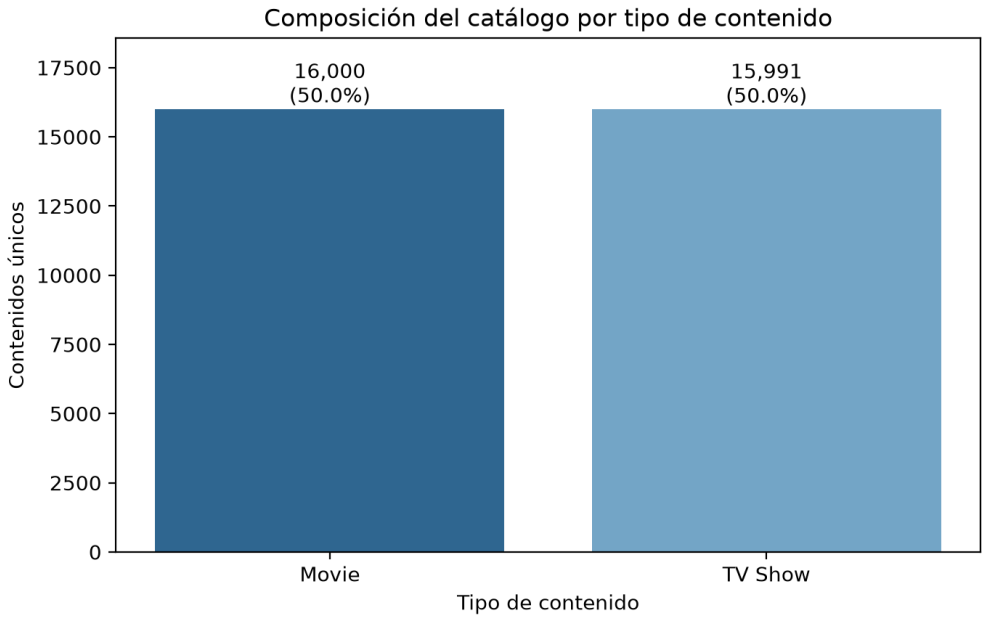
3. Reglas del modelo

La clave es content_id = type + '_' + show_id: show_id por sí solo colisiona entre películas y series. catalogo tiene una fila por contenido. Géneros, países, directores y actores usan tablas de puente, porque un contenido puede tener varios valores. Los conteos de estas dimensiones no se suman para obtener el total de títulos. finanzas contiene únicamente 3.540 películas con budget > 0 y revenue > 0. Los indicadores de valoración usan títulos con vote_count > 0. Nueve identificadores de series con popularidad en conflicto se excluyen de esa métrica.

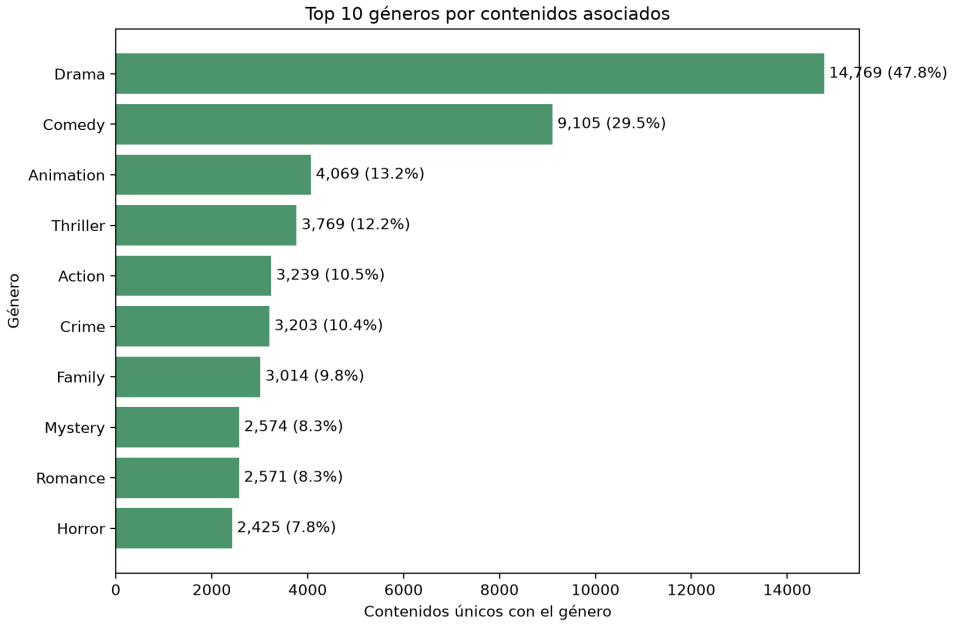
Los filtros se aplican al conjunto de contenidos antes de calcular indicadores. Se ofrecen tipo, periodo y género en ambas vistas; la vista de adquisición agrega país, idioma, calificación y umbrales de votos/cobertura.

4. Exploración y representación visual

La primera lectura compara la cantidad de películas y series. Las barras muestran el equilibrio entre ambas; la diferencia exacta de nueve títulos se indica aparte porque es casi imperceptible visualmente. Las barras ordenadas muestran concentración por género y país; sus etiquetas advierten que un contenido puede pertenecer a varias categorías. El mapa ofrece contexto espacial, mientras que las barras quedan como referencia cuantitativa exacta cuando el reconocimiento geográfico es ambiguo.

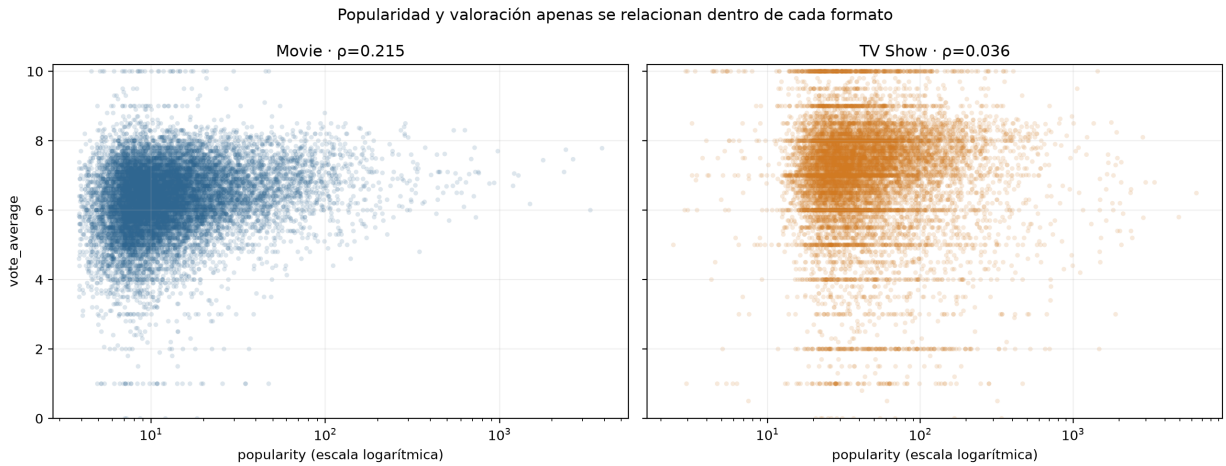


Distribución del catálogo por tipo; las películas y series tienen volúmenes cercanos.



Los géneros predominantes; las categorías se solapan.

La dispersión resulta apropiada para estudiar relaciones entre dos variables continuas sin esconder la variabilidad detrás de un promedio. La escala logarítmica de popularidad reduce el efecto visual de valores extremos; el tipo separa formatos distintos. Para elegir títulos se añade el número de votos, porque una nota alta con pocos votos es evidencia débil.



La relación entre popularidad y nota es débil dentro de cada formato.

5. Tablero ejecutivo

Al abrir sin filtros muestra 31.991 contenidos: 16.000 películas y 15.991 series. Hay 147 países, 83 idiomas y 28 géneros representados. Drama aparece en 14.769 títulos y Comedia en 9.105. Estados Unidos está asociado a 10.955 títulos, Japón a 2.869 y Reino Unido a 2.608. Inglés (en) aparece en 13.969 títulos. Estos números describen amplitud del catálogo, no audiencia ni reproducciones.

Las tarjetas KPI permiten ver el efecto de cada filtro. Las columnas por año muestran la distribución registrada en la fuente; date_added.year = release_year para todos los registros, por lo que no es válido inferir una política real de incorporación. El gráfico de tipo, las barras de países e idiomas, el treemap D3 de géneros y el mapa muestran composiciones complementarias. El mapa se interpreta como países asociados a producciones, no como consumo local.

La navegación comienza con esta vista general y pasa a la página analítica solo cuando se necesita evaluar candidatos. El treemap muestra participación relativa de géneros y permite explorar sus etiquetas; se complementa con barras porque las áreas son menos precisas para comparar valores cercanos. Las tarjetas y gráficos responden a los filtros de tipo, intervalo de años y género.

6. Tablero de contenidos y adquisición

La dispersión cruza popularidad relativa y calificación, con tamaño de punto ligado a votos y transparencia para reducir la superposición; así evita equiparar una nota alta con pocos votos a una evidencia sólida. En Streamlit, la popularidad mediana y la calificación media por género se muestran por separado; un gráfico de puntos con eje acotado permite comparar notas cercanas sin ocultar sus valores. El Top 10 de títulos exige un umbral de votos configurable. Los rankings de directores y actores representan solamente créditos informados; la cobertura de directores es parcial, especialmente en series.

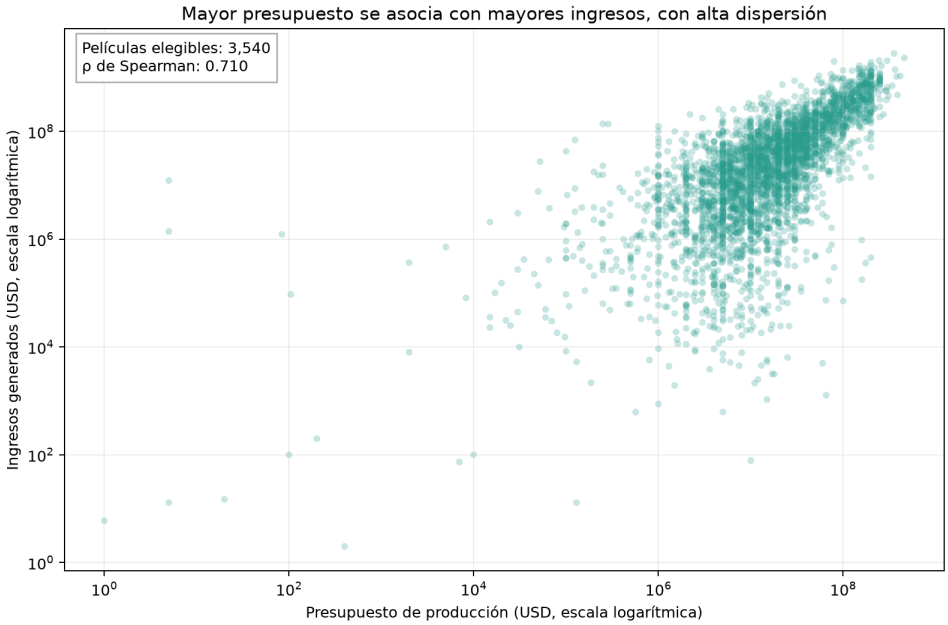
Para comparación geográfica de calificación, el mapa exige al menos 100 títulos valorados por país de forma predeterminada. Un ranking de puntos junto al mapa permite distinguir medias cercanas y consultar la cantidad de títulos valorados. Bajo ese umbral, Japón registra 2.647 títulos valorados y una media aproximada de 7,17/10; la cifra es descriptiva y no controla diferencias en composición del catálogo. Los filtros permiten volver a calcular estas vistas para un segmento concreto.

El recorrido de interacción es: acotar tipo, año, género, país, idioma y nota; inspeccionar la dispersión; subir el umbral de votos del Top 10; y comprobar la cobertura mínima antes de comparar países. La vista ofrece descarga CSV de la selección para auditoría. Power BI también incluye Top 10 con mínimo fijo de 100 votos, rankings de talento y un mapa de burbujas con mínimo fijo de 30 títulos. Streamlit permite ajustar ambos umbrales y muestra mapas coropléticos. Las dos herramientas usan las vistas preparadas de EP1, aunque sus controles y representaciones no son idénticos.

7. Módulo financiero

El subconjunto elegible es 3.540 de 16.000 películas (22,125 %). El presupuesto acumulado es 125.960.767.278 y los ingresos acumulados 367.371.433.138. La razón agregada ingresos/presupuesto es 2,9166×. Es un múltiplo bruto aproximado, no utilidad neta ni ROI porcentual. La convención USD proviene del informe anterior; los CSV no incluyen una columna que confirme divisa. La dispersión presupuesto–ingresos, el Top 10 de ingresos y las tarjetas contextualizan la variación por título.

La documentación de la evaluación 1 contiene totales ligeramente diferentes. Para esta entrega se prioriza el cálculo repetible desde los dos CSV presentes, con detalle en docs/conciliacion_financiera_ep2.md. No se mezclan ambas series de cifras.



Presupuesto e ingresos presentan asociación positiva y amplia dispersión entre películas elegibles.

La escala logarítmica en ambos ejes permite ver películas pequeñas y grandes en la misma dispersión; en Streamlit, la diagonal ingresos = presupuesto y dos colores muestran qué títulos superan esa referencia bruta. El múltiplo exacto permanece en el detalle del punto, sin dejar que valores extremos dominen una escala continua. La asociación positiva observada no implica que aumentar presupuesto cause ingresos mayores. El Top 10 de ingresos es útil para localizar extremos, pero una recomendación de adquisición exige revisar derechos y costos ausentes de estos CSV. La aplicación permite exportar el subconjunto financiero filtrado.

8. Evaluación crítica y límites

Fortalezas: ambos tableros comparten reglas y claves, los KPI se reconcilian con los CSV oficiales, los filtros actualizan el conjunto de entidades antes de agregarlo y el análisis financiero muestra su población elegible. La versión Power BI permite explorar medidas y relaciones en escritorio; la versión Python añade controles de umbral y descarga.

Oportunidades de mejora: incorporar una clasificación etaria verificada desde una fuente autorizada; reemplazar la fecha de incorporación por una fuente de eventos real; completar créditos y cobertura financiera; añadir pruebas de reconocimiento geográfico; y empaquetar los CSV oficiales por el canal permitido para ejecutar el proyecto en otro equipo. Los gráficos de Power BI y Streamlit cubren juntos los requisitos, pero no contienen las mismas vistas especializadas.

- El campo rating de los CSV coincide numéricamente con vote_average; no contiene categorías etarias confiables. Por ello no se presenta un filtro de clasificación por edad ni se imputan valores.

- popularity es un índice relativo del archivo, no una cifra de reproducciones.
- Los años 2010–2024 tienen exactamente 2.000 títulos cada uno y 2025 tiene 1.991. El patrón puede reflejar la construcción del archivo; no se interpreta como evolución del mercado.
- Un título puede tener varios géneros o países. Los totales por esas categorías se solapan.
- El mapa depende del reconocimiento de nombres de país de la herramienta; los valores tabulares son el control para decisiones precisas.
- Las finanzas solo cubren películas con ambas magnitudes positivas; sus resultados no representan la cartera completa.

9. Conclusiones y recomendaciones para las dos audiencias

Dirección ejecutiva: usar los indicadores de alcance y la composición por tipo, país e idioma para detectar concentración del catálogo. Revisar segmentos concretos antes de asignar objetivos; no interpretar la distribución por año como altas reales.

Contenidos y adquisición: combinar popularidad, valoración y volumen de votos para preparar una lista corta; usar los umbrales de cobertura en comparaciones geográficas. Evaluar los candidatos financieros con sus cifras individuales y sus costos completos fuera de este archivo antes de decidir inversiones.

10. Reproducción y verificación

Desde la raíz del repositorio: uv run --locked python -m unittest discover -s tests -v; uv run --locked python scripts/export_powerbi.py; uv run --locked streamlit run dashboard/app.py. Abrir powerbi/StreamView_EP2.pbip en Power BI Desktop y actualizar el modelo. Verificar 31.991 contenidos, 16.000 películas, 15.991 series y 3.540 películas financieras. El código, la función de preparación, el tema, la documentación y ambos tableros están en el proyecto local. Los CSV oficiales y las seis exportaciones están fuera de Git; para reproducir en otro equipo es necesario proporcionar los originales por el canal autorizado y regenerar las exportaciones y rutas de Power BI.